

Shaka

面向具身智能的证据驱动计划级自进化系统

从一次性任务规划走向可验证、可追溯、可持续改进的闭环智能

核心概念：具身智能的关键不只是生成一次动作，而是把每次运行暴露的偏差转化为下一轮可执行改进。Shaka 将“提出计划、受控运行、客观评价、证据反馈、再次规划”连接成可审计闭环，使系统的每一次变化都有依据、有边界、可复现。

P1 | 作品信息与核心结果

盖章报名表第一页

报名材料页另行装订。

盖章报名表第二页

报名材料页另行装订。

表 1 作品基本信息与摘要

挑战杯系统报名名称	以正式盖章报名表为准
最终参赛作品名称	Shaka：面向具身智能的证据驱动计划级自进化系统
参赛选题	赛道一·方向 1B · 科学实验任务规划与反馈迭代（XH-202619）
作品简介（300 字内）	具身智能要走向长期自主工作，核心能力不是偶然完成一次动作，而是从行动结果中识别偏差、形成下一轮方案，并保证目标、边界和评价标准不被偷换。Shaka 构建了一个证据驱动的计划级自进化系统原型：Qwen 把科学目标组织为受约束的结构化计划；实验运行程序在数字具身任务中产生轨迹与指标；独立判定程序给出逐项结论；原始证据再进入下一轮规划。系统保存计划差异、模型调用回执、对照实验与可重复工件，为未来接入高保真仿真和真实机器人建立可审计的闭环底座。
Qwen 与 AI 说明（300 字内）	基座模型为 Qwen3-Max，通过阿里云百炼 OpenAI 兼容端点调用。Qwen 在预先冻结的实验协议内生成假设、预期与可执行请求，并依据第一轮失败证据从限定参数域中选择第二轮控制量；它不定义科学问题、评价阈值或实验结果。结构化计划规范和程序检查共同保证任务、固定条件与安全边界不变。两次有效调用留存模型、脱敏 Request ID、token、时间及输入/输出 SHA-256；运行与判定由 Python 程序独立完成。

从长期愿景到本次实证

Shaka 面向的长期命题是：具身智能能否像研究者一样，让行动产生证据、让证据改变计划、让新的计划再次接受环境检验。为避免把远景写成既成事实，本作品将贡献划分为三个层级。

表 2 Shaka 的主张阶梯与证据边界

层级	含义	本作品状态
长期愿景	机器人在真实环境中持续提出、执行、评价并修订实验方案	发展方向，需要真实传感、物理授权和长期验证
系统目标	建立模型、运行程序、评价程序、证据仓库与人工授权协同的自进化闭环	已形成总体架构和可交互软件原型
本次实证	第一轮软件运行证据驱动第二轮结构化计划修订，且变化、判定和来源可复现	已由两次真实 Qwen 调用、确定性案例和对照实验验证

核心研究问题与代表结果

表 3 代表案例的研究问题、方法、结果与局限

具体研究问题	第一轮运行证据能否驱动 Qwen 形成可执行、可追踪的第二轮调整？
实际核心方法	Qwen 受约束规划 + 结构化边界检查 + 实验运行程序 + 独立逐项判定 + 证据留存与回放
代表性结果 1	固定基座与评价标准不变：第一轮三项未达门槛，系统判定“继续改进”；Qwen 调整三个控制量后，第二轮全部通过本轮软件门槛。
代表性结果 2	相同第一轮证据下，无反馈与固定规则方案仍需改进，Qwen 反馈方案通过本轮门槛；两轮各 20 次回放保持同一判定与指标向量。
主要局限	指标是软件契约夹具，不是传感器、物理引擎或真机测量；单案例不能推导 Qwen 成功率。

P2 | 作品目标、核心概念与决策权边界

为什么具身智能需要计划级自进化

一次性规划把智能停留在“行动之前”：模型给出方案，系统执行，结果却没有可靠路径返回规划环节。具身环境中的遮挡、偏移、接触误差和安全限制不会因为计划写得完整而消失。只有当运行结果被独立评价、失败原因被结构化保存、下一轮修改能够追溯到具体证据时，系统才具备最基础的自进化能力。

本作品所称“自进化”特指**计划级自进化**：模型参数没有训练，机器人技能也没有被宣称已经涌现；发生变化的是下一轮结构化计划。这个原语把未来更复杂的学习、仿真和真机实验建立在一个可审计的证据链上。

核心术语

表 4 首次出现术语的白话定义与代码对应

中文概念	含义	代码或数据中的名称
实验运行程序	把通过检查的计划转换为一次可重复的软件任务，生成动作路点、阶段轨迹和指标；不是机器人控制器或物理引擎	run_invocation
结构化计划规范	一张不可绕过的字段与范围检查表，保证任务、固定条件和门槛不被模型改写	JSON schema / validate_plan
逐项判定	程序把每个观测值与预先冻结的门槛逐项比较	checks
证据清单	记录每个工件的大小与哈希，可检测文件相对清单的变化；Git 提交历史提供外部时间点锚定	manifest
固定随机条件	用于产生可重复微小扰动的固定软件输入，不代表统计抽样	seed=11
安全授权状态	软件中的布尔门控；缺失时任务在动作前中止，不等于真实硬件安全系统	guardian=true/false
继续改进/本轮通过	任一门槛未满足则继续改进；全部门槛通过则结束本轮确定性案例	adjust/accept
完成/证据不足/中止	任务分支是否完成、是否因观测不足放弃、是否因保护条件缺失中止	succeeded/abstained/ aborted

谁决定什么

表 5 研究者、Qwen 与程序的决策权分离

角色	可以决定	不能决定
研究者	科学问题、评价门槛、允许变量、证据等级、物理授权与最终结论	不在成功周期内部事后改写已保存计划或结果
Qwen	组织假设、预期和停止条件；在限定参数域内选择下一轮控制量；解释证据与变化关系	不能改任务、固定基座、门槛、结果或物理授权
边界检查程序	判断计划字段、固定条件与参数范围是否合法	不生成科学结论，不替模型选择调整方案
实验运行与判定程序	运行软件任务、生成指标、逐项比较门槛并给出本轮决策	不调用 Qwen 修改结果，不把软件结论升级为物理结论

实际完成的工作

- 通过百炼调用 Qwen3-Max，完成两次有效模型请求并保存脱敏回执；
- 形成“第一轮计划 → 受控运行 → 独立评价 → 证据反馈 → 第二轮计划 → 同口径再运行”的案例包；
- 冻结科学问题、基座位姿、任务、固定随机条件、安全授权状态、成功标准和参数边界；
- 生成计划差异、无反馈/规则式/Qwen 三策略对照、参数空间审计、证据清单与只读验证器；

- 主动测试遮挡、保护缺失、非法输入、不可用真机模式和模型越界计划。

计划级自进化的最小闭环




图 1 计划级自进化的最小闭环。来源：本项目设计。反馈连线沿模块外侧返回 Qwen，不穿过任何节点。

表 6 闭环输出、验证范围与相对一次性规划的变化

主要输出	两轮计划、运行结果、逐项评价、计划差异、策略对照、重复性、Qwen 回执、API 与报告
验证范围	确定性软件任务；不含真实 G1、真实传感器和物理引擎实验
相较一次性方案	第二轮参数逐项对应第一轮保存结果，通过模型外门禁后才能执行

本作品完成的是“证据驱动下一轮计划”的计划级自进化原语，为后续高保真仿真和真机验证提供可审计底座。

P3 | 本作品采用的科学逻辑与实验判断

表 7 从科学问题到停止规则的判断链

判断环节	实际做法	理由
区分事实、假设、推断	已有事实：API/阈值/回执；模型推断：Qwen 计划；契约仿真：程序输出；待验证：真机结论	防止计划被写成事实、仿真被写成物理证据
目标转为任务	固定任务、3 个允许变量、4 项门槛与停止条件	每项计划均可执行和检查
预期与证伪	任一门槛未满足即“继续改进”；全部通过才“本轮通过”	结果能削弱或支持工作假设
异常与替代解释	指标标为构造夹具；同值重复只代表确定性	不外推为机器人能力
继续/调整/停止	未达项连同原始指标返回 Qwen；越界计划被拒绝；全部通过后按预设规则结束本轮	反馈来源与停止理由可复核

科学逻辑

- 已有事实**：实验运行程序对固定基座与给定控制量产生固定软件输出；阈值两轮不可改；Qwen 不能写入任务结果。
- 工作假设**：在固定基座条件下，第一轮失败证据可指导 Qwen 改变动作计划并满足全部软件准入阈值。
- 支持条件**：置信度 ≥ 0.95 、接触误差 $\leq 3.0\text{mm}$ 、速度占比 ≤ 0.60 、间隙 $\geq 40\text{mm}$ ，且任务分支成功。
- 第一轮反馈**：0.943、3.19mm 与 0.658 三项越界，基线动作计划未通过。
- 模型推断**：Qwen 认为延长观察、减小接近幅度和放慢动作可分别回应失败项；只有第二轮执行后才获得软件层支持。
- 竞争解释**：改善可能仅来自手写确定性公式的单调性，而非 Qwen 掌握真实机器人动力学。

表 8 代表案例的变量、控制条件与后续验证对象

自变量	observation_duration_ms、approach_scale、motion_duration_scale
因变量	四项构造型指标与“继续改进/本轮通过”判定
控制变量	固定基座 0.18/-0.08/12°、问题、任务、固定随机条件、场景、安全授权状态、运行程序、阈值与判定代码
待验证	真实视觉定位、接触误差、动力学安全与 G1 成功率

第二轮“本轮通过”只表示通过预先冻结的软件门槛，不表示真实 G1 任务成功。

P4 | 本作品实际使用的数据、资料与实验条件

表 9 数据、模型与程序在案例中的作用

实际内容	如何使用	作用与局限
Qwen3-Max/百炼	OpenAI 兼容端点， temperature=0，结构化 JSON 对象	生成两轮计划；仍需程序检查字段与范围
第一轮上下文	问题、事实、假设、允许变量、阈值与停止条件	约束计划；无真实传感输入
第一轮原始结果	请求、轨迹、指标、摘要	第二轮反馈；指标由公式构造
模型外评价	每项门槛的真/假判断与本轮决策	防止 Qwen 自行宣布成功；阈值非行业标准
实验运行程序	Python 标准库运行shifted_base 数字任务	验证闭环生命周期，不是物理仿真器
代码与测试	定向单元/E2E、只读验证器、 OpenAPI、Git	验证结构、回放与失败语义，不验证物理性能

实际处理方法

表 10 数据进入闭环前的处理与边界规则

可用性检查	请求必须为 JSON 对象；模式、场景、固定随机条件、安全授权状态、固定基座与控制量范围由程序检查
单位/坐标/时间	x/y 为米、yaw 为度；本案例无采样频率与跨时钟数据
缺失与冲突	Qwen 案例字段必须齐全；阈值、固定随机条件或范围冲突直接拒绝
能力边界	只开放 3 个动作控制量；禁止改基座、任务、场景、运行程序与阈值；软件结果不自动升级为物理声明
原始与派生	计划、原始结果、程序评价和模型调整分文件保存
来源、许可与凭证	未使用外部数据集，案例数据均由本项目程序生成；源码仓库公开可访问，但当前未声明项目级开源许可证；百炼密钥只在本机读取，脱敏调用回执留存

控制量如何影响数字任务

表 11 三个可控量与四项构造指标的方向关系

控制量	在动作计划中的作用	在确定性测试夹具中的方向性
观察时长	决定观察路点持续时间	延长时长提高构造定位置信度，并降低构造接触误差
接近幅度	缩放接近与接触阶段的七维手臂增量	减小幅度降低构造接触误差与速度比，并增大构造间隙
动作时标	拉伸接近、接触和撤离阶段持续时间	增大时标降低构造峰值速度比

完整公式、四路点七维增量和状态字段下沉至在线技术文档：<https://v6582374-netizen.github.io/Shaka/#/implementation-evidence>。

实验条件清单

macOS/Python 标准库；模型qwen3-max；服务来自 Alibaba Cloud Model Studio；固定随机条件为 11；场景为偏移基座；安全授权状态开启；无机器人写入，无真实相机、DDS、接触传感器或物理引擎。

本阶段验证对象是“证据如何进入下一轮计划”，物理世界中的感知、动力学和安全结论将由更高证据等级承担。

P5 | 本作品采用的评价方法

表 12 评价对象、方法及其对下一轮的影响

评价内容	方法与对象	对下一轮影响
结构化计划有效性	程序检查轮次、固定随机条件、场景、安全状态、基座、控制量、阈值和文本字段	不合规即拒绝，不运行
任务分支结果	程序检查软件任务分支是否完成	未完成即继续改进
构造型准入指标	四项指标按冻结阈值逐项布尔比较	失败项和原值返回 Qwen
计划可追踪性	核对三项失败 check、原值/门槛、控制量 from/to 与冻结字段	只接受证据触发的有界调整
反馈策略对照	无反馈、固定规则、Qwen 反馈；共享第一轮证据与预算	判断反馈策略是否改变软件结果
确定性复现	两轮各 20 次，统计判定、摘要指纹和指标向量	只声明软件确定性

冻结评价口径

表 13 四项构造指标的预先冻结门槛

指标	通过条件	两轮口径
目标定位信度（构造）	≥ 0.95	相同
预测接触误差（构造）	$\leq 3.0\text{mm}$	相同
峰值速度占比（构造）	≤ 0.60	相同
最小间隙（构造）	$\geq 40\text{mm}$	相同

表 14 评价权、停止规则、口径来源与资源代价

评价主体	关键结果由程序计算；Qwen 解释与调整；团队人工核对证据边界
继续/停止	越界计划被拒绝；任一门槛未满足则继续改进；全通过后按本轮规则停止；物理主张须经人工审批
口径来源	为软件案例预先冻结，不宣称来自真实 G1 标定或领域共识
资源代价	两次有效 Qwen 调用共 3490 tokens；确定性回放不调用模型

如何避免系统“自证成功”

评价门槛在模型调用前冻结，原始任务结果由实验运行程序产生，逐项判断由独立函数完成。Qwen 只能读取这些证据并提出下一轮方案，不能修改门槛、覆盖结果或把解释写回原始工件。这种权责分离使“模型提出计划”和“系统判定结果”成为两条相互校验的链路。

Qwen 提出可检验方案，程序决定本轮是否通过；被评价模型无权修改评价口径。

P6 | 系统总体架构与技术闭环

核心概念：系统由三种彼此制衡的能力组成：Qwen 提出方案，程序负责边界检查、运行与判定，研究者保留真实物理执行和科学结论的授权。自进化发生在证据返回规划层之后，而不是由模型自行宣布成功。




图 2 Shaka 具身智能计划级自进化总体架构。来源：使用 OpenAI 图像生成能力依据本项目真实模块生成，并经人工逐项核对文字、拓扑和证据边界。主流程采用蛇形单向布局，所有反馈连线均绕开模块与标签；中部为数字具身任务示意，不代表真实机器人实验。

三层系统如何协同

总体架构从“目标与规划”开始：科学问题先转化为冻结协议，Qwen 只能在协议允许的空间内生成结构化计划。通过边界检查后，计划进入“受控运行与判定”层，由实验运行程序产生数字动作、轨迹和指标，再由独立规则判断是否达到本轮门槛。所有计划、结果、判定和差异进入“证据与进化”层，形成下一轮计划并沿外侧反馈回 Qwen。人工授权边界始终位于闭环之外，防止软件案例自动升级为物理操作。

表 15 总体架构各模块的输入、职责与输出

模块	输入	核心处理	输出/下一模块
目标与约束	问题、事实、假设	固定变量、阈值、证据等级	第一轮上下文
Qwen 规划	结构化上下文	形成假设、预期、停止条件和有界控制量	边界检查
受控运行	已验证请求	规范化、确定性分支、动作路点、原始结果与摘要	程序评价
结果判断	任务结果与指标	冻结阈值逐项比较	反馈对象
反馈调整	第一轮计划、结果、逐项判定	Qwen 映射失败项到有界参数调整	第二轮计划
证据/API	全部对象	独立 JSON、证据清单、脱敏回执、只读验证与重放	公开复现入口
人工边界	报告与未验证项	审核身份、物理授权与科学结论	停止/线下验证

为什么不是一次性生成

第二轮上下文包含第一轮真实保存的计划、请求、指标和逐项判定。Qwen 必须指出哪个数值越过哪条门槛、因此把哪个参数从什么改成什么；新计划再次通过同一边界检查和实验运行程序。换题、改变固定随机条件、放宽阈值或替换场景均无法进入下一轮。

实现取舍

闭环只增加一个 Qwen 规划模块和一组独立证据工件，没有引入数据库、消息总线或通用 workflow 平台。单目录即可组成可验证案例包，复杂度集中在“权责分离与证据可追溯”，而不是中间件数量。

本次案例走数字具身任务路径；总体架构为后续接入高保真仿真和真实机器人预留人工授权接口，但不会把未来能力写成当前成果。

P7 | Qwen 使用方式与上下文工程

表 16 Qwen 在两轮闭环中的任务、输入、约束与追踪信息

内容	实际做法
模型/调用	Qwen3-Max；通过阿里云百炼兼容接口完成两次有效调用
具体任务	第一轮计划；读取第一轮证据；解释失败；提出第二轮有界调整
上下文	问题、事实、假设、证据等级、条件、阈值、第一轮计划/原始结果/程序评价
格式约束	JSON 对象；固定字段；字符串数组；任务、固定随机条件、阈值与基座冻结；控制量有界
工具协作	Qwen 提出计划 → 边界检查 → 实验运行程序 → 独立判定 → 新上下文 → Qwen
追踪	服务方、模型、脱敏调用标识、时间、token 与输入/输出内容指纹；不记录 API Key

本地案例重放界面




图 3 本地 Shaka Test Bench 重放已留存两轮案例的界面。运行环境：macOS 本地 API；左侧为任务输入，右侧同时显示两轮判定、软件运行边界和证据清单校验状态，关键区域见下一页局部放大。来源：本项目真实运行截图。




图 4 重放界面的证据区域局部放大。可直接读取“继续改进 → 本轮通过”、无物理执行、两轮计划标识和证据清单验证状态。来源：图中同一次本地运行。

两轮上下文如何发生变化




图 5 第二轮上下文相对第一轮只新增运行证据与逐项判定。来源：本项目两轮计划和结果工件。所有连线均沿节点外部连接。

减少无依据规划

- 1. system prompt 禁止 Markdown 与思维过程，只接受完整 JSON；
- 2. 校验器冻结边界并最多允许三次针对明确错误的纠正；
- 3. Qwen 不能覆盖任务结果；
- 4. 原始结果、程序评价、模型解释分别保存；
- 5. 第二轮问题逐字一致且参数只能进入预设范围。

无反馈基线没有读取第一轮结果，因此原样保持 250ms/1/1 并继续改进；加入结构化原始指标与逐项判定后，Qwen 输出 500ms/.85/1.20，并由同一运行和判定程序确认全部门槛通过。这说明运行证据真实进入了调整链路；策略贡献仍需由对照和更多任务进一步验证。

调用证据如何留存

表 17 两次有效百炼调用的角色、资源与可追踪性

轮次	规划任务	token 用量	留存证据
第一轮	在冻结协议内形成初始计划	1087	模型身份、时间、脱敏调用标识与输入/输出指纹
第二轮	读取失败证据并形成有界调整	2403	同一证据结构，并关联第一轮计划、结果与逐项判定

两次有效调用共 3490 tokens。完整上下文、调用标识、字段与哈希关系见在线“实现与证据细节”页面。

P8 | 实验任务规划方法

表 18 任务规划从目标拆解到运行准入的五个环节

规划环节	实际做法	中间结果/执行作用
拆解目标	计划生成、执行取数、四项检查、反馈调整、再执行	两轮可比较任务链
依赖顺序	先保存计划再执行；先程序判断再允许 Qwen 调整	防止事后补写
参数条件	基座两轮固定；第一轮控制量精确固定；第二轮三个控制量有界	可执行请求与四路点动作
冲突检查	类型、场景、保护、阈值、范围、问题一致性	越界不执行
预期/停止	Qwen 列预期与失败条件；程序执行冻结门槛	直接决定继续改进或本轮通过

一份可运行计划包含什么

表 19 结构化计划的六类信息及其作用

信息类别	主要内容	作用
身份与轮次	计划标识、轮次、任务标识	连接调用、结果和计划差异
科学语义	工作假设、预期观测、停止条件	让计划可以被结果支持或削弱
固定协议	基座、场景、固定随机条件、安全状态、评价门槛	保证两轮回答同一个问题
允许控制量	观察时长、接近幅度、动作时标	构成第二轮可调整空间
运行请求	直接传给实验运行程序的结构化对象	防止人工重录造成漂移
变化说明	每个参数从何值改到何值、对应哪项证据	建立失败证据与新计划的因果链

三个控制量如何改变四路点动作




图 6 两轮四路点动作计划的结构差异。来源：主案例两轮 result JSON。第二轮延长观察与各运动阶段，并缩小接近、接触阶段的七维关节增量；图示为软件动作计划，不是真机轨迹。

计划如何交付执行

Qwen 输出先由边界检查程序核对；通过后的运行请求直接进入实验运行程序，不经过人工重新录入。程序返回动作路点、阶段轨迹、指标和证据摘要，第二轮重复同一路径。完整 JSON 字段、四路点七维增量和验证函数见在线技术文档。

结构化计划不是说明文字，而是连接 Qwen、运行程序和评价程序的可执行接口；任何越界字段都会在运行前被拒绝。

P9 | 实验或仿真实际执行与数据获取

表 20 两轮运行、模型调用和对照回放的数据流

环节	工具/输入	原始结果	后续用途
Qwen 第一轮	百炼；问题与冻结条件	结构化计划、脱敏调用标识、token、SHA-256	边界检查与运行
第一轮运行	实验运行程序；固定基座 0.18/-0.08/12°	请求、路点、轨迹、构造指标、摘要	独立评价与反馈
Qwen 第二轮	第一轮计划、原始结果和逐项判定	调整计划、理由、第二次回执	边界检查与再运行
第二轮运行	同一固定基座； 500ms/0.85/1.20	同结构原始结果与四路点动作	同口径比较
对照/回放	无反馈、规则式、Qwen；每轮 20 次	三策略判定、参数网格与指标向量	P18/P19

执行前检查

- 运行请求必须是结构化对象，位姿和控制量必须为数值；
- 两轮基座精确为 0.18m、-0.08m、12°；

- 第一轮控制量固定为 250ms/1/1，第二轮只能在 250–650ms、.80–1、1–1.30 内；
- 运行模式、场景、固定随机条件、安全授权状态与阈值不可改；真实机器人模式在本原型中不可用。

原始结果与模型内容

表 21 模型生成内容、程序生成内容与证据工件的分层

Qwen 生成	两份计划对象；属于模型提出的方案与解释
程序原始输出	两份运行结果；属于数字任务产生的动作与指标
程序派生评价	两份评价对象；包含逐项判定与本轮决策
证据与对照	调用回执、计划差异、策略对照、参数空间审计和证据清单

实际范围

无真实仪器、视频、DDS、MuJoCo 或接触力数据，无机器人写入。“置信度、误差、速度比和间隙”来自确定性测试夹具，用于验证反馈链路能否读取并响应数值。真实机器人授权、仪器操作和最终科学结论属于下一证据等级；本案例没有用人工结果替代未执行的物理实验。

真实调用与真实程序运行不等于真实物理实验。

P10 | 数据分析、质量控制与反馈形成

表 22 原始请求如何转化为可追溯反馈

分析环节	输入	方法/结果	质量与反馈
规范化	Qwen 运行请求	补齐固定任务和指令并生成内容指纹	绑定输入身份
结果计算	固定基座、固定随机条件与动作控制量	确定性测试夹具生成指标和四路点动作	明确标为数字软件任务
质量判断	任务分支与指标	冻结阈值逐项比较	任一未达项进入继续改进
异常检查	结构、模式与安全状态	非法计划、模式不可用或保护中止	不进入伪成功
预期比较	门槛与原始指标	逐项判定、本轮决策、冻结标准	完整传入第二轮
摘要留存	上下文、计划与结果	规范化 JSON 与 SHA-256	检测相对已发布证据清单的变化

结果变成反馈




图 7 第一轮原始指标经过独立逐项判定后形成第二轮反馈对象。来源：主案例结果与评价工件。连线仅按单向证据流连接，不穿过节点。

表 23 模型、程序和人工在反馈形成中的分工

直接反馈	任务分支、规范化请求、全部指标，不只传一个成功标签
程序计算	规范化、测试夹具指标、逐项判定、本轮决策与摘要
Qwen 解释	哪个失败指标触发哪个参数变化及新预期
避免主观裁决	Qwen 无权写任务结果；评价函数不调用模型；阈值必须完全相等
人工复核	核对证据来源、物理边界和最终科学表述，不改程序判定

不确定性

实验运行程序没有统计噪声，因此不计算显著性；20 次相同输出只证明软件确定性。真实噪声、标定误差和域偏移留待高保真仿真与物理实验。

P11 | 本作品实际采用的反馈与计划调整方法

表 24 第一轮未达项到第二轮控制量的证据映射

反馈信号	系统识别	判断	第二轮调整
0.943< 0.95	程序比较	定位准入失败	观察时长 250 → 500ms
3.19> 3.0mm	程序比较	接触误差失败	接近幅度 1.00 → 0.85
0.658> 0.60	程序比较	峰值速度失败	动作时标 1.00 → 1.20
40.27≥ 40mm	程序比较	通过但近门槛	不改阈值, 继续观察
计划越界	边界检查程序	不可运行	拒绝并返回明确错误
全部通过	全部门槛为真	本轮通过	按预设规则结束本轮

一项真实调整示例

第一轮出现 0.943 低于 0.95、3.19mm 高于 3.0mm、0.658 高于 0.60。程序先判定“继续改进”，再把原始数值和未达项传给 Qwen。Qwen 将观察时长 250→500ms、接近幅度 1.00→0.85、动作时标 1.00→1.20；固定基座、任务、随机条件、场景、安全状态、运行程序与阈值不变。

反馈机制

1. 只读取结构化逐项判定, 不从自然语言日志猜原因;
2. 不允许 Qwen 改评价标准, 只能在预设空间调整;
3. 每项变化必须说明证据来源;
4. 独立导出计划差异;
5. 无反馈对照原样重放第一轮。

周期内约束与周期间选择

在当前成功周期内部, 系统没有更换固定随机条件、移动基座、放宽阈值、修改公式或允许 Qwen 写入任务结果。更早一次正式周期为“继续改进 → 继续改进”; 团队随后澄清“无需追求最小改动, 应保留安全余量”的规划目标, 再产生当前主案例。因此, 当前周期内部的证据链完整, 但主案例选择受到前一失败周期反馈影响, 不能用于估计 Qwen 成功率。

本周期证明证据能够驱动有界计划修订; 它不证明任意提示下 Qwen 都能一次找到通过方案。

P12 | 完整运行流程与实际失败处理




图 8 完整运行状态机。来源：本项目 API 生命周期与计划校验逻辑。主流程水平展开，拒绝、异常和反馈分支垂直分离，回路沿节点外侧返回 Qwen。

表 25 主动测试的异常分支与系统响应

主动测试情况	发现/处理	影响
改变冻结阈值	PlanningError	不执行, 不伪造结果
改变固定随机条件、基座或控制量超范围	定向测试拒绝	保持两轮可比
目标遮挡	证据不足, 动作计划为空	不用猜测补足观测
保护缺失	动作前中止	自动停止
真机模式	HTTP 409	不降级成仿真成功
非法请求	HTTP 422 机器可读错误	客户端修正
证据清单被篡改	只读验证失败	不重放、不覆盖主案例

自动与人工边界

自动：结构解析、边界检查、软件运行、阈值判断、摘要、对照和复现。**人工：**仪器与机器人授权、物理风险、领域阈值来源、真机证据和最终科学结论。

保留变化

每轮计划、结果和评价独立保存；证据清单记录全部 JSON 的大小与哈希；计划差异单独导出；只读验证器重放结果且不覆盖主案例。已发布 Git 提交与远端历史提供外部版本锚定。

失败不是一个状态，而是四种知识边界

表 26 不同失败类型对下一步行动和知识主张的影响

类型	发生条件	系统动作	允许形成的结论
计划拒绝	模型改动冻结字段、越过参数范围或改变科学问题	不运行，返回明确边界错误	只能说明方案不合规，不能评价任务能力
证据不足	目标遮挡或观测不足，无法形成动作依据	放弃本次动作并保留空计划	只能说明当前观测不支持行动
安全中止	保护状态缺失、真实模式未授权或运行异常	在动作前停止并转人工	只能说明安全边界生效，不构成任务失败样本
软件未达标	数字任务完成，但任一冻结门槛未满足	保存原始指标并进入下一轮规划	可以驱动计划修订，不能外推为物理失败
本轮通过	数字任务完成且四项门槛全部满足	按预设规则结束当前案例	只支持当前软件口径，不自动获得稳健或物理结论

失败处理为何决定自进化质量

如果系统把所有失败都简化为一个红色标签，下一轮规划就无法区分“方案越界”“看不清”“不安全”和“运行后未达标”。Shaka 只有在最后一种情况下才允许证据进入 Qwen 并改变下一轮控制量；前三种情况分别要求纠正计划、补充观测或取得人工授权。自进化因此不是盲目重试，而是根据失败的本体类型选择不同的知识更新路径。

能否正确停止，与能否正确继续同样重要；错误地把拒绝或中止当作学习样本，会让闭环从证据驱动退化为结果驱动。

自动系统可以拒绝越界计划，但不能审批真实机器人实验或替代领域专家的科学判断。

P13 | 代表性案例选择与实际设置

核心概念：“黄色按钮接触”被选为最小可证伪任务：观察多久、接近多大、动作多慢三项控制量都能在第一轮失败后被明确追问，同时科学问题、外部条件与评价门槛保持不变。它承载的是闭环机制验证，而非机器人能力展示。

表 27 代表案例的选择逻辑与能力边界

科学问题/目标	检验第一轮运行证据能否触发 Qwen 形成可执行、同口径的第二轮调整
选择理由	固定基座、仅 3 个动作控制量、第一轮确定三项失败、第二轮存在可验证有界改动
展示能力	真实 Qwen 调用、上下文更新、边界检查、程序裁决、计划差异、对照与复现
不能代表	真实 G1、视觉定位、接触动力学、高保真仿真、跨任务泛化或统计显著性

实际初始条件

表 28 主案例的固定条件、可控变量与评价范围

已有证据	确定性实验运行程序、公开接口、保护与遮挡分支；无真实传感器数据
对象/条件	黄色按钮接触任务；偏移基座场景；固定随机条件为 11；安全授权状态开启
可控变量	观察时长、接近幅度、动作时标；其余条件冻结
固定条件	基座 0.18m、-0.08m、12°，两轮均不得修改
第一轮控制	250ms、1.00、1.00，模型必须原样输出
希望观测	四项夹具指标、task result、动作计划、阶段轨迹
评价方法	程序逐项比较四个冻结门槛；任一失败即进入继续改进
第二轮范围	观察 250–650ms、接近.80–1.00、时标 1.00–1.30；45 点审计含 15 个本轮通过、30 个继续改进

主案例的选择边界

第一轮采用预先固定的边界外基线，第二轮由 Qwen 在限定范围内调整。更早一次正式周期停留在“继续改进 → 继续改进”，团队随后将规划目标从“尽量小改”澄清为“在允许空间内保留安全余量”，才形成当前成功周期。因此，本案例能够证明一条完整证据链已经运行，不能用于估计 Qwen 在任意提示下的成功率。

运行前冻结

科学问题、固定基座、任务、固定随机条件、场景、安全授权状态、阈值、第二轮参数域、判定函数和物理证据禁区均在运行前冻结。计划先保存再执行，避免根据结果反向补写。

这是人为设计的软件边界案例，不能替代总体机器人表现。

P14 | 第一轮实验任务计划

表 29 第一轮从模型规划到程序评价的任务链

步	任务/动作	主要参数	预期观测	停止/调整
1	组装上下文并调用 Qwen	温度为 0；结构化对象；证据等级固定	计划含问题、请求、阈值、预期、停止条件	字段错误则拒绝并纠正
2	结构化边界检查	第一轮；固定随机条件 11；基座 0.18/-0.08/12°	所有冻结字段一致	改任务或阈值则停止
3	运行数字任务并保存结果	偏移基座；安全授权状态开启 .95 / 3.0mm	任务分支、指标、路点、轨迹与摘要	保护或模式异常则中止
4	程序评价	.60 / 40mm	四项逐项判定与本轮决策	任一未达则形成反馈

计划形成过程

表 30 第一轮计划中模型、程序与人工的职责分离

目标/证据/约束	问题；运行对象是数字软件任务；固定基座，仅 3 个动作控制量；判定程序与阈值不可改
Qwen 完成	工作假设、预期观测、停止条件与理由，可执行请求
程序完成	结构检查、规范化、运行、指标构造、阈值判断与摘要
执行检查	通过检查的请求直接交给实验运行程序；第一轮条件精确匹配；无外部系统写入
人工修改	当前成功周期的第一轮计划未被人工改写；程序只验证或拒绝
分步资源/耗时	步骤 1 消耗 Qwen 1087 tokens；步骤 2-4 仅用 Python 标准库在本机执行，近即时且未单独计时；无机器人、仪器或人工改写计划

预期与证伪

Qwen 预期基线控制可能使观察不足、接近过大、动作过快；任一门槛失败即必须调整而非改标准。间隙通过不能抵消其他三项失败。

证据身份

第一轮计划、调用回执、运行结果和程序评价分别保存，并以内容指纹相互关联。完整标识、字段与原始对象下沉至在线“实现与证据细节”页面。

在当前成功周期内，计划在执行前由 Qwen 生成并保存，没有根据结果反向补写预期。

P15 | 第一轮实验执行与结果

表 31 第一轮实际运行步骤、原始结果与证据边界

步	动作/参数	原始结果	质量/差异	资源
1	固定基座； 250ms/1/1	数字任务完成并生成唯一运行标识	摘要一致	本地即时
2	动作/阶段生成	4 路点、7 阶段；物理执行为否；外部写入为零	只证明接口形式	无机器人
3	保存指标	0.943；3.19mm；0.658；40.27mm	前三项失败，间隙通过	单次请求
4	程序评价	未达、未达、未达、通过；继续改进	完整保留失败	确定性

第一轮评价

表 32 第一轮四项冻结门槛的逐项评价

内容	口径	结果	达到
任务分支	数字任务完成	数字任务完成	是
置信度（构造）	≥ .95	.943	否
接触误差（构造）	≤ 3.0mm	3.19mm	否
速度占比（构造）	≤ .60	.658	否
最小间隙（构造）	≥ 40mm	40.27mm	是
综合判定	全部通过	继续改进	未通过

不确定性

数值由确定性公式生成，无测量噪声、真值标定或置信区间。0.943 和 3.19mm 是触发门槛的测试夹具，不能解释为相机测量或真实接触误差。

原始工件

三份第一轮结构化对象分别保存计划、原始结果与程序评价；评价明确记录“模型未赋予任务结果”。字段级证据、哈希与复现命令见 GitBook。

数字任务完成不等于综合实验通过；第一轮的真实结论是“继续改进”。

P16 | 第一轮问题分析与调整依据

表 33 第一轮未达项、竞争解释与第二轮调整

问题	判断依据	可能原因/替代解释	第二轮调整
置信度 0.943	低于 0.95	观察窗口不足的构造响应；非真实视觉退化	观察时长 250→500ms
误差 3.19mm	高于 3.0mm	观察/接近控制的构造响应；非接触真值	接近幅度 1.00→0.85
速度 0.658	高于 0.60	动作时标的构造响应；非真实动力学测量	时标 1.00→1.20
间隙通过	40.27 满足	不是全部指标共同恶化	不改阈值/任务/保护
证据等级有限	physical=false	改善可能仅来自公式单调性	仍只作软件验证

触发逻辑

1. 程序保存结果后生成“继续改进”和四项逐项判定；
2. 第二轮上下文包含计划、请求、指标与未达项；
3. Qwen 必须保留问题、固定基座、固定随机条件、运行模式、场景、安全状态与评价标准；
4. 三个控制量只能在预设范围内改变；
5. 程序逐项核对失败项、观测值、门槛与参数变化。

保持不变

任务内容与顺序、固定基座、实验运行程序、评价函数、阈值、固定随机条件、保护状态、场景、输出结构和证据等级全部不变，以便把数值变化归因到动作控制量。

两类贡献必须分开

控制量对构造指标的影响由确定性测试夹具规定；Qwen 的贡献不是“发现了这些公式”，而是读取第一轮未达项后，在允许空间中形成一个新的组合。当前对照支持该组合优于无反馈和既定规则方案，但不足以证明 Qwen 掌握真实接触动力学。

预期与代价

预期置信度上升、误差下降、速度降低且间隙继续通过；新增一次 Qwen 调用（2403 tokens）和证据管理成本，但不增加物理真实性。

第二轮首先证明数字任务对控制量发生了预期响应；Qwen 策略本身的贡献由同条件对照限定，而不是由单次通过自行证明。

P17 | 第二轮实验计划、执行与结果

表 34 两轮固定条件、控制量与程序判定的同口径比较

变化	第一轮	第二轮	原因/结果
任务/顺序	黄色按钮；计划 → 运行 → 评价	相同	同题；数字任务均完成
基座位姿	.18/- .08/12°	.18/- .08/12°	固定不变
观察时长	250ms	500ms	0.943 低于 .95；R2 定位置信度 .958 通过
接近幅度	1.00	.85	3.19mm 高于 3.0；R2 为 2.99mm，仅余 .01mm
动作时标	1.00	1.20	.658 高于 .60；R2 速度占比 .466 通过
数据获取	同一实验运行程序与结构	相同	产生独立第二轮运行工件
分析	四项冻结门槛	相同	四项均通过
停止	任一失败则继续改进	全通过则本轮停止	执行预设停止规则

两轮同口径结果

表 35 两轮构造指标、变化方向与最终判定

构造指标	第一轮	第二轮	变化
定位置信度	.943	.958	+.015
接触误差/mm	3.19	2.99	-.20
速度占比	.658	.466	-.192
最小间隙/mm	40.27	40.87	+.60
程序判定	继续改进	本轮通过	跨过软件门槛

第二轮结论

表 36 第二轮能够支持与不能支持的结论

改善	三项失败指标跨过门槛；间隙继续通过；动作计划四个路点真实改变
余量	接触误差 2.99mm 仅比 3.0mm 门槛低 0.01mm；不称稳健通过，需更多任务/噪声证据
未改善/代价	未增加物理真实性、样本多样性或统计证据；增加模型调用和结构化规范维护
对最初判断	支持固定基座下有界动作反馈可改变软件准入判定
停止理由	预设规则要求四项全通过后结束当前确定性案例；下一步转向噪声、任务变化、高保真仿真与物理验证，而非继续消费同一夹具

改善是同一软件口径下由“继续改进”变为“本轮通过”，不升级为稳健性结论或物理成功。

P18 | 实际对照、参数空间与方案优势

同条件反馈策略消融



图 9 三种反馈策略在同一第一轮证据和评价口径下的第二轮输出。来源：主案例策略对照工件。该对照只回答反馈策略是否改变软件计划与判定，不回答真实机器人性能。

表 37 三种反馈策略的共同条件、结果与解释边界

对象	相同条件	结果	结论/代价
无反馈基线	共享第一轮证据、参数预算、固定随机条件、运行程序与评价；原样重放第一轮	继续改进； 250ms/1/1	不读取结果就无计划变化
规则式反馈	同上；固定规则 450ms/.90/1.10	继续改进；误差 3.04mm	简单规则仍卡在门槛外
Qwen 反馈	同上；把原始结果和逐项判定传给 Qwen；再做边界检查	本轮通过； 500ms/.85/1.20	改变软件判定；增加 2403 tokens

45 点参数空间审计




图 10 离散参数空间的 45 点审计结果。来源：参数空间审计工件。三个动作时标面板分别组合 5 档观察时长与 3 档接近幅度，共 15 个本轮通过、30 个继续改进；Qwen 方案与规则方案位于同一连续允许域，但不一定落在离散网格上。

公平性与可解释边界

三策略共享第一轮证据、参数预算、固定随机条件、实验运行程序与评价口径；第二轮控制量是各策略各自输出，因此不宣称“同一执行输入”上的性能提升。45 点审计说明通过区域并非唯一孤点，但当前案例仍不足以支持跨任务策略排名。

对照回答反馈机制是否改变下一轮软件计划与判定，不回答机器人性能提升多少。

P19 | 总体结果、失败分析与演进路线

表 38 本作品当前能够支持与尚不能支持的主张

本作品已经证明	本作品尚未证明
真实 Qwen 调用进入了两轮计划链；第一轮证据能够追溯到第二轮参数；主成功周期可按同一程序口径重放，其回执与哈希可查；早期失败周期保留摘要及调用标识	真实 G1 成功率；视觉或力觉测量准确性；复杂任务泛化；统计显著性；长期自主实验；任何物理安全授权

表 39 案例、对照、回放与异常测试的证据规模

范围	轮次/样本	主要结果	重复/问题
Qwen 案例	2 轮、2 次有效调用	继续改进 → 本轮通过；完整计划差异	单案例不可泛化
策略对照	无反馈/规则式/Qwen	继续改进/继续改进/本轮通过	指标为构造夹具
确定性回放	R1 20 次、R2 20 次	各 20/20 相同；指标向量各 1	只证明确定性
定向测试	单元、端到端与只读校验	全通过；覆盖边界检查、证据清单与回放入口	未覆盖配额与网络抖动
任务分支	4 类场景	完成、证据不足、中止均可复现	非物理结果

失败与边界

表 40 已暴露失败模式、根因边界与当前处理

问题	表现/原因	当前程度
模型格式可能越界	结构化输出不保证业务边界全部合法	最多 3 次明确纠正；不合规不执行
模型调整可能不足	首次正式周期为继续改进 → 继续改进	不改阈值；澄清安全余量目标，失败周期单独披露
静态 Pages 无 API	交互页需本地/Codespaces API	文档已明确启动/配置
指标无物理真值	公式夹具，无图像/传感器/物理引擎	只验证反馈链路
真实 G1 未闭环	案例无物理执行	需授权、标定、保护与不可变证据
门槛余量过小	第二轮接触误差仅低于门槛 0.01mm	不称稳健；下一阶段引入噪声和任务变化

成功周期选择边界

首次正式周期为“继续改进 → 继续改进”，第二轮误差仍为 3.05mm；当时完整包未被保留，只留下捕获摘要与调用标识。当前成功周期来自规划目标修订，不能推导 Qwen 成功率；系统现已改为独立留存未来失败周期。

P19 | 演进蓝图与证据门槛

核心概念：具身智能的自进化不是一次跨越，而是一条证据逐级升级的道路：环境越真实、行动权限越大、长期影响越深，系统就越需要更强的对照、授权与不可变记录。Shaka 当前完成的是这条道路的第一块可运行基石。

表 41 四阶段演进路线及其进入下一阶段的证据门槛

阶段	核心能力	进入下一阶段前必须回答的问题
计划级闭环	一次运行的证据可以改变下一轮结构化计划，且任务、边界和评价口径不被偷换	跨不同任务与扰动时，改进是否仍然稳定，而非只适配单个确定性夹具？
稳健性闭环	在噪声、分布变化和多任务条件下评价策略，保留失败周期与反事实对照	改进是否来自可迁移策略，而非偶然选择、提示词偏置或评价漏洞？
高保真具身闭环	接入物理引擎、真实感知模型、技能库与世界模型，让计划面对动力学和部分可观测性	仿真中的收益能否经过域随机化、标定和安全测试迁移到真实设备？
长期真机闭环	在人工授权、硬件联锁和责任追踪下持续运行，使经验跨周期积累	系统是否在长期尺度上提高科学产出，同时控制遗忘、风险、成本与错误累积？

从计划级闭环走向具身自进化




图 11 Shaka 从当前计划级闭环走向长期具身自进化的证据阶梯。来源：本项目演进蓝图。每一阶段都要求新增证据，不允许由上一层软件结果自动升级。

演进过程中保持不变的系统骨架

表 42 证据来源逐级升级时仍需保持的三项架构原则

原则	保持不变	随阶段替换
权责分离	模型提出方案，程序产生与评价证据，人工掌握物理授权和最终科学结论	运行对象从软件任务升级为仿真器、传感器和真实设备
证据先于结论	计划先保存、结果独立产生、门槛预先冻结、失败不可覆盖	指标从构造夹具升级为标定测量、物理轨迹和长期统计
最小闭环	只保留目标、计划、运行、评价、反馈与授权六类必要角色	逐步增强每一角色的真实性，而不是堆叠新的通用中间层

最强结论是“可审计的 Qwen 两轮软件反馈闭环已运行”，不是“自主机器人科学家已完成”。

P20 | 证据入口与长期蓝图

核心概念：PDF 回答“Shaka 为什么存在、如何形成自进化闭环、当前证据达到哪一层”；GitBook 回答“字段如何定义、公式如何计算、接口如何调用、工件如何校验”。两者共同构成蓝图与工程底座，而不是在一份文档中混合叙事与实现手册。

表 43 蓝图层、证据层与实现层的公开入口

交付	内容/入口
宏大叙事与成果边界	本技术报告：总体问题、架构、权责、案例、对照、失败与演进路线
实现与证据细节	GitBook“实现与证据细节”： https://v6582374-netizen.github.io/Shaka/#/implementation-evidence
源码与工程环境	https://github.com/v6582374-netizen/Shaka ；包含程序、测试、公开接口与开发环境
代表案例与对照	仓库中的 Qwen 反馈周期工件：两轮计划、结果、评价、差异、回执、对照与参数空间审计
交互与回放	本地或云开发环境中的 Shaka Test Bench；公开静态站点提供启动与复现说明
版本与完整性	证据清单检测工件相对清单的变化；Git 提交和远端历史提供外部版本锚定

长期蓝图中的三条主线

表 44 Shaka 未来演进的能力主线、证据要求与不可逾越边界

主线	下一阶段要建立的能力	必须新增的证据
世界交互	从确定性数字任务扩展到带噪声、多任务、高保真仿真与真实传感	分布外任务、扰动实验、标定记录、真实轨迹和失败样本
持续改进	从单周期计划修订扩展到跨周期策略记忆、技能复用与长期评价	版本化策略、遗忘与迁移测试、长期基准和反事实对照
可信治理	从软件边界检查扩展到设备授权、风险控制、责任追踪与科学复核	人工批准、硬件联锁、不可变日志、领域阈值与外部审计

当前系统在蓝图中的位置

Shaka 已经跨过“一次性生成”的门槛：行动结果能够回到规划层，并以可执行、可比较、可拒绝的方式改变下一轮计划。它尚未跨过“真实世界学习”的门槛：没有模型权重更新、技能涌现、长期记忆或真机科学发现。未来工作的价值不在于给现有闭环堆叠更多中间层，而在于逐级替换证据来源——从确定性夹具到噪声任务，从高保真仿真到人工授权的真实环境，同时保持同一套权责分离和可追溯原则。

Shaka 的蓝图不是让模型获得无限权限，而是让每一次能力扩展都伴随更高等级的证据、更清晰的授权和更严格的可复现性。