

Shaka

Qwen 驱动的科学实验任务规划与反馈迭代

让实验结果真正改变下一轮计划

给评委的阅读提示：先抓住一句话：**Qwen 负责提出可检验的计划，确定性程序负责执行和裁决，第一轮结果再返回 Qwen 形成第二轮。**全文以 P1-P20 保留官方检查索引，但按“问题 → 方法 → 案例 → 证据”连续讲述，不要求一段占一页。

P1 | 作品信息与核心结果

待补：盖章报名表第一页

最终提交前替换；当前技术审查不据此猜测身份。

待补：盖章报名表第二页

最终提交前替换；当前技术审查不据此猜测身份。

挑战杯系统报名名称	待按盖章报名表核对，不猜测填写
最终参赛作品名称	Shaka: Qwen 驱动的科学实验任务规划与反馈迭代系统
参赛选题	赛道一·方向 1B · 科学实验任务规划与反馈迭代 (XH-202619)
作品简介 (300 字内)	面向“一次性计划无法吸收运行结果”的问题，Shaka 把科学问题、冻结条件和可证伪标准组织成结构化上下文，由 Qwen3-Max 生成第一轮计划；确定性程序执行契约仿真、保存原始结果并在模型外完成阈值判断；Qwen 读取第一轮证据后提出有界调整，再以相同执行器和评价口径完成第二轮。代表案例留存两次百炼真实调用、完整上下文、计划差异、结果、对照与重复性材料。当前只证明软件反馈闭环，不声称真实 G1 或物理仿真结论。
Qwen 与 AI 说明 (300 字内)	基座模型为 Qwen3-Max，通过阿里云百炼 OpenAI 兼容端点调用。Qwen 承担问题结构化、第一轮规划、结果解释和第二轮参数调整；JSON schema 与确定性校验器冻结任务、seed、阈值和参数范围，模型不能自行赋予任务结果。两次有效调用保存 provider、模型、Request ID、token、时间和输入/输出 SHA-256，API Key 不写入仓库。执行与裁决由 Python 程序完成。

本作品核心主张

具体研究问题	第一轮运行证据能否驱动 Qwen 形成可执行、可追踪的第二轮调整？
实际核心方法	Qwen 规划/调整 + schema 门禁 + 确定性执行/裁决 + 摘要证据
代表性结果 1	固定基座不变：Round 1 三项失败，程序判定adjust；Qwen 调整三个控制量后 Round 2 四项通过，判定accept。
代表性结果 2	同条件下无反馈与固定规则均为adjust，Qwen 反馈为accept；两轮各 20 次回放均保持同一判定与指标向量。
主要局限	指标是软件契约夹具，不是传感器、物理引擎或真机测量；单案例不能推导 Qwen 成功率。

推荐阅读路径

如果时间有限，请先看 P6-P7 理解系统职责，再看 P13-P17 跟随一次完整的两轮案例，最后用 P18-P20 核对对照、边界与复现材料。P3-P5 提供科学判断与评价口径，供进一步追问时查证。

P2 | 作品目标与实际完成内容

团队实际解决的问题


许多所谓“实验规划智能体”止步于写出一份看起来合理的方案。真正困难的是：运行后得到的结果由谁判断、失败如何传回模型、下一轮究竟改了什么，以及团队是否在看到结果后偷偷改了评价标准。Shaka 只解决这条最关键的证据链：先让 Qwen 提出受约束的计划，再由模型外程序执行和裁决，最后把第一轮原始结果与逐项判定返回 Qwen。于是第二轮不再是“重新写一份方案”，而是一次可以追问来源、比较差异和重复回放的调整。

给评委的阅读提示：文中的“结构化校验 (schema)”可理解为一张不可绕过的检查表；“逐项判定 (checks)”是程序给每个门禁打勾或打叉；“工件清单 (manifest)”则用哈希证明证据文件没有被悄悄替换。

实际完成的工作

- 通过百炼调用 Qwen3-Max，完成两次有效模型请求并保存脱敏回执；
- 形成“第一轮计划 → 契约执行 → 程序评价 → 反馈 → 第二轮计划 → 同口径再执行”的案例包；
- 冻结科学问题、基座位姿、任务、seed、保护状态、成功标准和参数边界；
- 生成计划差异、无反馈/规则式/Qwen 三策略对照、参数空间审计、manifest 与只读验证器；
- 主动测试遮挡、保护缺失、非法输入、不可用真机模式和模型越界计划。

完整闭环



主要输出	两轮计划/结果/评价、plan diff、对照、重复性、Qwen 回执、API 与报告
实际范围	确定性契约仿真；不含真实 G1、真实传感器和物理引擎实验
相较一次性方案	第二轮参数逐项对应第一轮保存结果，通过模型外门禁后才能执行

完整的是软件反馈闭环；未完成的是物理科学验证。二者不互相替代。

P3 | 本作品采用的科学逻辑与实验判断

判断环节	实际做法	理由
区分事实、假设、推断	已有事实：API/阈值/回执；模型推断：Qwen 计划；契约仿真：程序输出；待验证：真机结论	防止计划被写成事实、仿真被写成物理证据
目标转为任务	固定任务、3 个允许变量、4 项门槛与停止条件	每项计划均可执行和检查
预期与证伪	任一检查失败即 adjust；全部通过才 accept	结果能削弱或支持工作假设
异常与替代解释	指标标为构造夹具；同值重复只代表确定性	不外推为机器人能力
继续/调整/停止	失败 → 原始指标和 checks 返回 Qwen；越界 → 拒绝；通过 → 停止软件案例	反馈来源与停止理由可复核

科学逻辑

- 已有事实**：执行器对固定基座与给定动作控制量产生固定软件输出；阈值两轮不可改；Qwen 不能写task_result。
- 工作假设**：在固定基座条件下，第一轮失败证据可指导 Qwen 改变动作计划并满足全部软件准入阈值。
- 支持条件**：置信度 ≥ 0.95 、接触误差 $\leq 3.0\text{mm}$ 、速度占比 ≤ 0.60 、间隙 $\geq 40\text{mm}$ ，且任务分支成功。
- 第一轮反馈**：0.943、3.19mm 与 0.658 三项越界，基线动作计划未通过。
- 模型推断**：Qwen 认为延长观察、减小接近幅度和放慢动作可分别回应失败项；只有第二轮执行后才获得软件层支持。
- 竞争解释**：改善可能仅来自手写确定性公式的单调性，而非 Qwen 掌握真实机器人动力学。

自变量	observation_duration_ms、approach_scale、motion_duration_scale
因变量	四项构造型指标与adjust/accept
控制变量	固定基座 0.18/-0.08/12°、问题、任务、seed=11、场景、保护、执行器、阈值与判定代码
待验证	真实视觉定位、接触误差、动力学安全与 G1 成功率

“第二轮 accept”只表示通过软件契约门槛，不表示真实 G1 任务成功。

P4 | 本作品实际使用的数据、资料与实验条件

实际内容	如何使用	作用与局限
Qwen3-Max/百炼	OpenAI 兼容/chat/completions, temperature=0, JSON 对象	生成两轮计划；仍需业务 schema
第一轮上下文	问题、事实、假设、允许变量、阈值与停止条件	约束计划；无真实传感输入
第一轮原始结果	请求、轨迹、指标、摘要	第二轮反馈；指标由公式构造
模型外评价	每项布尔检查与 decision	防止 Qwen 自行成功；阈值非行业标准
Python 执行器	标准库运行shifted_base	验证生命周期，不是物理仿真器
代码与测试	定向单元/E2E、只读验证器、OpenAPI、Git	验证结构、回放与失败语义，不验证物理性能

实际处理方法

可用性检查	请求必须为 JSON 对象；模式、场景、seed、保护、固定基座与动作控制量范围由程序检查
单位/坐标/时间	x/y 为米、yaw 为度；本案例无采样频率与跨时钟数据
缺失与冲突	Qwen 案例字段必须齐全；阈值、seed 或范围冲突直接拒绝，不猜测
能力边界	只开放 3 个动作控制量；禁止改基座、任务、场景、执行器与阈值；禁止物理声明
原始与派生	计划、原始结果、程序评价和模型调整分文件保存
来源、许可与凭证	未使用外部数据集，案例数据均由本项目程序生成；源码仓库公开可访问，但当前未声明项目级开源许可证；百炼密钥只在本机读取，脱敏调用回执留存

实验条件清单

macOS/Python 标准库；模型qwen3-max；provider 为 Alibaba Cloud Model Studio；两轮 seed=11；场景shifted_base；guardian=true；无机器人写入；无真实相机、DDS、接触传感器或物理引擎。

当前交付可核验的是模型调用与软件执行数据，不伪造仪器条件。

P5 | 本作品采用的评价方法

评价内容	方法与对象	对下一轮影响
计划契约有效性	schema 检查 round、seed、场景、保护、固定基座、控制量、阈值和文本数组	不合规即拒绝，不执行
任务分支结果	程序检查task_result==succeeded	失败即 adjust
构造型准入指标	四项指标按冻结阈值逐项布尔比较	失败项和原值返回 Qwen
计划可追踪性	核对三项失败 check、原值/门槛、控制量 from/to 与冻结字段	只接受证据触发的有界调整
反馈策略对照	无反馈、固定规则、Qwen 反馈；共享第一轮证据与预算	判断反馈策略是否改变软件结果
确定性复现	两轮各 20 次，统计 decision/digest/指标向量	只声明软件确定性

冻结评价口径

指标	通过条件	两轮口径
目标定位置信度（构造）	≥ 0.95	相同
预测接触误差（构造）	$\leq 3.0\text{mm}$	相同
峰值速度占比（构造）	≤ 0.60	相同
最小间隙（构造）	$\geq 40\text{mm}$	相同

评价主体	关键结果由程序计算；Qwen 解释与调整；团队人工核对证据边界
继续/停止	越界 → 拒绝；任一检查失败 → 调整；全通过 → 停止软件案例；物理主张 → 人工审批
口径来源	为软件案例预先冻结，不宣称来自真实 G1 标定或领域共识
资源代价	两次有效 Qwen 调用共 3490 tokens；确定性回放不调用模型

模型提出可证伪计划，程序决定是否通过；被评价模型无权修改评价口径。

P6 | 系统总体架构与技术闭环

给评委的阅读提示：这张图的关键不是模块数量，而是三种权力彼此分开：模型只能提计划，程序才能给出通过或调整，研究者仍负责物理授权和最终科学结论。




图 1 | 实际闭环：第一轮结果连同逐项失败原因进入第二轮 Qwen 上下文，而不是在写入报告后结束。

模块	输入	核心处理	输出/下一模块
目标与约束	问题、事实、假设	固定变量、阈值、证据等级	第一轮上下文
Qwen 规划	结构化上下文	JSON 计划、预期、停止条件与理由	schema 门禁
契约执行	已验证请求	规范化、确定性分支、原始结果与摘要	程序评价
结果判断	任务结果与指标	冻结阈值逐项比较	反馈对象
反馈调整	第一轮计划、结果、checks	Qwen 映射失败项到有界参数调整	第二轮计划
证据/API	全部对象	独立 JSON、manifest、脱敏回执、只读验证/重放	评审复现
人工边界	报告与未验证项	审核身份、物理授权与科学结论	停止/线下验证

为什么不是一次性生成

第二轮上下文包含第一轮真实保存的计划、请求、指标和逐项检查。Qwen 必须指出哪个数值越过哪条门槛、因此把哪个参数从什么改成什么；新计划再次通过同一校验器和执行器。换题、改 seed、放宽阈值或改变场景均无法通过。

Minimalism

闭环只增加一个 Qwen 规划模块和一组 JSON 工件，没有数据库、消息总线或通用 workflow 平台；单目录就是可复现案例包。

图中的真机与零写入模块是 Shaka 总体资产；本次代表案例实际走确定性契约仿真路径。

P7 | Qwen 使用方式与上下文工程

内容	实际做法
模型/调用	qwen3-max；阿里云百炼 https://dashscope.aliyuncs.com/compatible-mode/v1/chat/completions
具体任务	第一轮计划；读取第一轮证据；解释失败；提出第二轮有界调整
上下文	问题、事实、假设、证据等级、条件、阈值、第一轮计划/原始结果/程序评价
格式约束	JSON object；固定字段；字符串数组；任务/seed/阈值/基座冻结；控制量有界
工具协作	Qwen→schema→执行器 → 程序判断 → 新上下文 →Qwen
追踪	provider、模型、Request ID、时间、token、prompt/response SHA-256；不记录 API Key

真实可交互界面

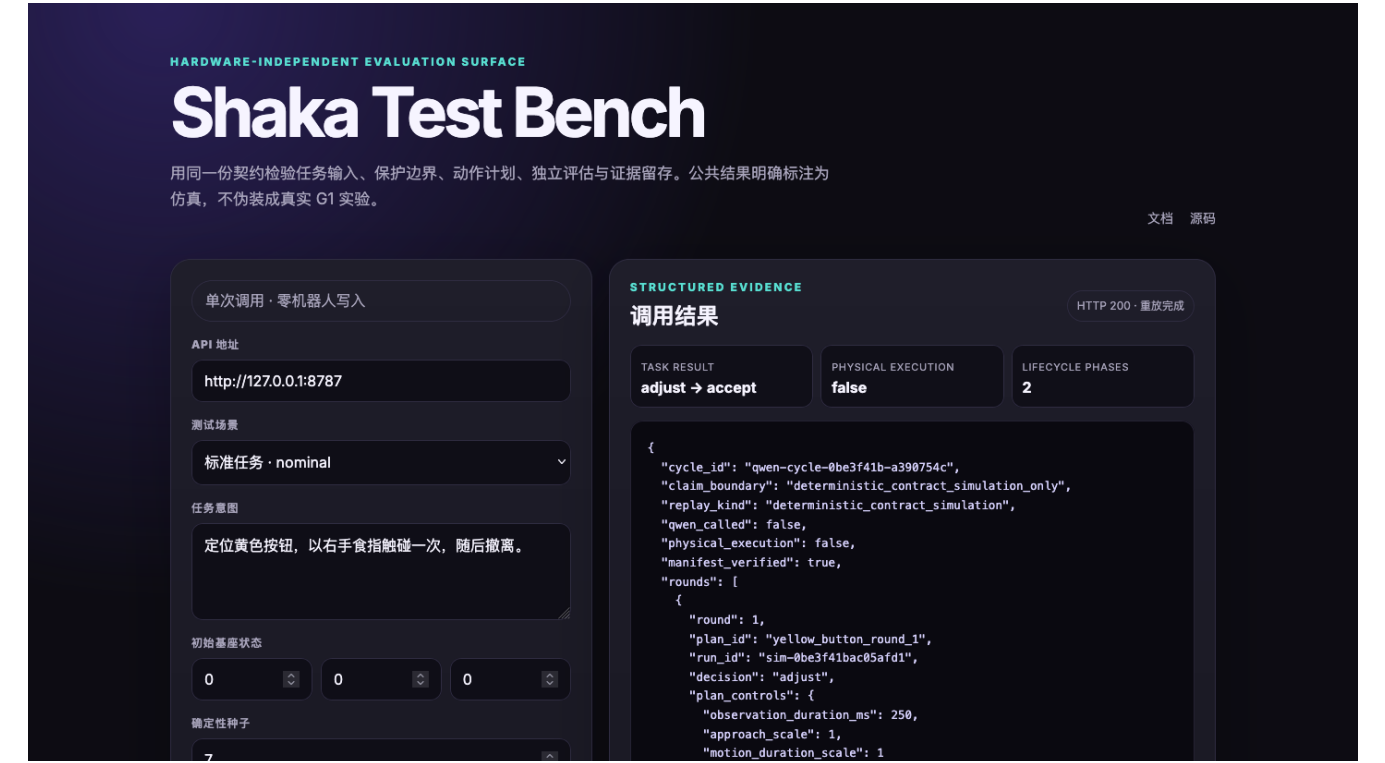


图 2 | 本地真实界面点击“重放两轮计划”后的状态。右侧直接显示adjust→accept、physicalexecution=false、两轮计划和manifest_verified=true；截图不是概念原型。

真实上下文结构



减少无依据规划

- 1. system prompt 禁止 Markdown 与思维过程，只接受完整 JSON；
- 2. 校验器冻结边界并最多允许三次针对明确错误的纠正；
- 3. Qwen 不能覆盖任务结果；
- 4. 原始结果、程序评价、模型解释分别保存；
- 5. 第二轮问题逐字一致且参数只能进入预设范围。

实际变化：不提供第一轮证据的无反馈基线原样保持 250ms/1/1 并继续adjust；加入结构化原始指标与 checks 后，Qwen 输出 500ms/.85/1.20 并经同一执行器得到accept。该单例只能证明上下文进入了调整链路，不能单独归因或泛化为模型能力提升。

脱敏回执

轮	Request ID	Prompt	Completion	Total	模型
1	chatcmpl-c7dd766d-e698-9239-b713-423b7d26f2cb	614	473	1087	qwen3-max
2	chatcmpl-00e923b3-6b35-970b-97bb-7dd390696bc9	1555	848	2403	qwen3-max

Plan ID 分别为yellow_button_round_1/2；两次有效调用共 3490 tokens；完整回执保存端点、时间和 SHA-256，密钥值从未留存。

P8 | 实验任务规划方法

规划环节	实际做法	中间结果/执行作用
拆解目标	计划生成、执行取数、四项检查、反馈调整、再执行	两轮可比较任务链
依赖顺序	先保存计划再执行；先程序判断再允许 Qwen 调整	防止事后补写
参数条件	基座两轮固定；Round 1 控制量精确固定；Round 2 三个控制量有界	可执行 request 与四路点动作
冲突检查	类型、场景、保护、阈值、范围、问题一致性	越界不执行
预期/停止	Qwen 列预期与失败条件；程序执行冻结门槛	直接决定 adjust/accept

第一轮真实计划片段

```
{
  "plan_id": "yellow_button_round_1",
  "round": 1,
  "evidence_status": "deterministic_contract_simulation_only",
  "request": {
    "mode": "simulation", "scenario": "shifted_base", "seed": 11,
    "guardian_present": true,
    "initial_state": {"base_x_m": 0.18, "base_y_m": -0.08,
                      "base_yaw_deg": 12.0},
    "plan_controls": {"observation_duration_ms": 250,
                      "approach_scale": 1.0,
                      "motion_duration_scale": 1.0}
  },
  "success_criteria": {
    "min_localization_confidence": 0.95,
    "max_predicted_contact_error_mm": 3.0,
    "max_peak_joint_velocity_ratio": 0.60,
    "min_clearance_mm": 40.0
  }
}
```

计划如何交付执行

Qwen 输出由validate_plan 验证；通过后的request 直接传给run_invocation，不是人工重录。执行器返回请求摘要、动作路点、阶段轨迹、评价对象和证据摘要。第二轮重复同一路径。

其他计划字段

工作假设、预期观测、停止条件、相对上一轮变化及理由。第一轮changes_from_previous 必须为空；第二轮必须包含由第一轮证据触发的变化。

只有通过 schema 的 Qwen 计划对象才能触发执行；中间结果是接口，不是文案。

P9 | 实验或仿真实际执行与数据获取

环节	工具/输入	原始结果	后续用途
Qwen Round 1	百炼；问题与冻结条件	JSON 计划、Request ID、token、SHA-256	schema 与执行
Round 1 执行	Python 执行器； 0.18/-0.08/12°	请求、路点、轨迹、构造指标、摘要	程序评价/反馈
Qwen Round 2	R1 计划 + 原始结果 +checks	调整计划、理由、第二回执	schema 与再执行
Round 2 执行	同一固定基座； 500ms/0.85/1.20	同结构原始结果与四路点动作	同口径比较
对照/回放	无反馈、规则式、Qwen； 每轮 20 次	三策略判定、参数网格与指标向量	P18/P19

执行前检查

- request 必须是对象，位姿和控制量必须为数值；
- 两轮基座精确为 0.18m、-0.08m、12°；
- Round 1 控制量为 250ms/1/1，Round 2 只能在 250–650ms、.80–1、1–1.30 内；
- mode、scenario、seed、guardian、阈值不可改；真机模式返回 409。

原始结果与模型内容

Qwen 生成	两个 plan JSON；属于模型计划与解释
程序原始输出	两个 result JSON；属于契约执行数据
程序派生评价	两个 assessment JSON；逐项 checks 与 decision
证据/对照	receipts、plan-diff、method-comparison、parameter-space-audit、manifest

实际范围


无真实仪器、视频、DDS、MuJoCo 或接触力数据，无机器人写入。“置信度/误差/间隙”来自core.py 确定性公式，只用于验证反馈链路是否读取和响应数值。范围外的真机授权、仪器操作、报名核验和最终科学结论只能由人工线下完成；本案例没有用人工或离线结果替代未执行的物理实验。

真实调用与真实程序运行不等于真实物理实验。

P10 | 数据分析、质量控制与反馈形成

分析环节	输入	方法/结果	质量与反馈
规范化	Qwen request	补齐固定 task/instruction 并生成 digest	绑定输入身份
结果计算	固定基座、seed 与动作控制量	确定性公式生成夹具指标/四路点动作	标明 illustrative simulation
质量判断	task result+ 指标	冻结阈值逐项布尔比较	任一 false→adjust
异常检查	schema/模式/保护	PlanningError、409、aborted	不进入伪成功
预期比较	标准与原始指标	checks、decision、frozen criteria	完整传入 Round 2
摘要留存	上下文/计划/结果	canonical JSON+SHA-256	检查内容未替换

结果变成反馈



直接反馈	task result、规范化请求、全部指标，不只传成功标签
程序计算	规范化、夹具指标、checks、decision、摘要
Qwen 解释	哪个失败指标触发哪个参数变化及新预期
避免主观裁决	Qwen 无权写任务结果；评价函数不调用模型；阈值必须完全相等
人工复核	核对回执、密钥、边界和 P1-P20 映射，不改程序判定

不确定性

执行器没有统计噪声，因此不计算显著性；20 次相同输出只证明软件确定性。真实噪声、标定误差和域偏移留待物理/高保真仿真。

P11 | 本作品实际采用的反馈与计划调整方法

反馈信号	系统识别	判断	Round 2 调整
0.943< 0.95	程序比较	定位准入失败	观察时长 250 → 500ms
3.19> 3.0mm	程序比较	接触误差失败	接近幅度 1.00 → 0.85
0.658> 0.60	程序比较	峰值速度失败	动作时标 1.00 → 1.20
40.27≥ 40mm	程序比较	通过但近门槛	不改阈值，继续观察
schema 越界	validate_plan	不可执行	拒绝并反馈明确错误
全部通过	all(checks)	accept	停止软件案例

一项真实调整示例

第一轮出现0.943<0.95、3.19>3.0 与0.658>0.60。程序先生成adjust，再把原始数值和 checks 传给 Qwen。Qwen 将观察时长 250→500ms、接近幅度 1.00→0.85、动作时标 1.00→1.20；固定基座、任务、seed、场景、保护、执行器与阈值不变。

反馈机制


- 1. 只读结构化 checks，不从自然语言日志猜原因；
- 2. 不允许 Qwen 改评价标准，只能在预设空间调整；
- 3. 每项变化在changes_from_previous 说明来源；
- 4. 导出plan-diff.json；
- 5. 无反馈对照原样重放第一轮。

未采用

没有换 seed、改 scenario 为 nominal、移动基座、放宽阈值、修改公式或让 Qwen 写 task result。第一次正式调用产生adjust→adjust 时也未改阈值，而是修正缺失的“安全余量”规划目标后重新形成完整周期。

调整是证据到参数的有向映射，不是重新抽样一个更好看的方案。

P12 | 完整运行流程与实际失败处理



主动测试情况	发现/处理	影响
改变冻结阈值	PlanningError	不执行，不伪造结果
改变 seed/基座/控制量超范围	定向测试拒绝	保持两轮可比
目标遮挡	abstained，动作计划为空	证据不足不伪判
保护缺失	动作前 aborted	自动停止
真机模式	HTTP 409	不降级成仿真成功
非法请求	HTTP 422 机器可读错误	客户端修正
P1 报名材料缺失	红色待补槽位	团队必须提供盖章截图

自动与人工边界

自动：JSON 解析、schema、执行、阈值判断、摘要、对照和复现。**人工：**报名身份、仪器/机器人授权、物理风险、领域阈值来源、真机证据和最终科学结论。

保留变化

每轮计划/结果/评价独立保存；manifest 绑定全部 JSON；plan diff 单独导出；只读验证器重放结果且不覆盖主案例。

自动系统可以拒绝越界计划，但不能补报名信息或审批真实机器人实验。

P13 | 代表性案例选择与实际设置

给评委的阅读提示：“黄色按钮”不是为了证明机器人已经会按按钮，而是为了把反馈过程讲清楚：观察多久、接近多大、动作多慢，三项控制量都能在第一轮失败后被明确追问，且其他条件可以保持不变。

科学问题/目标	检验第一轮运行证据能否触发 Qwen 形成可执行、同口径的第二轮调整
选择理由	固定基座、仅 3 个动作控制量、第一轮确定三项失败、第二轮存在可验证有界改动
展示能力	真实 Qwen 调用、上下文更新、门禁、程序裁决、plan diff、对照与复现
不能代表	真实 G1、视觉定位、接触动力学、高保真仿真、跨任务泛化或统计显著性
实际初始条件	
已有证据	确定性执行器、OpenAPI、保护/遮挡语义；无真实传感器数据
对象/条件	g1-yellow-button-contact-v1; shifted_base; seed=11; guardian=true
可控变量	observation_duration_ms/approach_scale/motion_duration_scale; 其余冻结
固定条件	基座 0.18m、-0.08m、12°，两轮均不得修改
第一轮控制	250ms、1.00、1.00，模型必须原样输出
希望观测	四项夹具指标、task result、动作计划、阶段轨迹
评价方法	程序逐项比较四个门槛；任一失败即 adjust
第二轮范围	观察 250–650ms、接近.80–1.00、时标 1.00–1.30；45 点审计含 15 个 accept/30 个 adjust

不是“最好个案”

第一轮故意选择准入边界外条件，不隐藏失败。第二轮由 Qwen 在限定范围内调整；无反馈对照仍为 adjust。价值在证据链，而非数值好看。

运行前冻结

科学问题、固定基座、任务/seed/场景/保护、阈值、Round 2 参数域、判定函数和物理证据禁区。计划先保存再执行，避免结果后补。

这是人为设计的软件边界案例，不能替代总体机器人表现。

P14 | 第一轮实验任务计划

步	任务/动作	主要参数	预期观测	停止/调整
1	组装上下文并调用 Qwen	temp=0; JSON; 证据等级固定	计划含问题、请求、阈值、预期、停止条件	字段错误 → 拒绝纠正
2	schema 门禁	round=1; seed=11; 0.18/-0.08/12°	冻结字段全部通过	改任务/阈值 → 停止
3	契约执行并保存结果	shifted_base; guardian=true .95 / 3.0mm	task、指标、路点、轨迹、摘要	保护/模式异常 → 中止
4	程序评价	.60 / 40mm	每项 check 与 decision	任一 false→ 反馈

计划形成过程

目标/证据/约束	问题；执行器是契约仿真；固定基座，仅 3 个动作控制量；评估器/阈值不可改
Qwen 完成	工作假设、预期观测、停止条件与理由，可执行请求
程序完成	schema、规范化、执行、指标构造、阈值判断与摘要
执行检查	request 直接通过run_invocation；第一轮条件精确匹配；无凭证写入
人工修改	有效 Round 1 计划未人工改写；程序只验证/拒绝
分步资源/耗时	步骤 1 消耗 Qwen 1087 tokens；步骤 2-4 仅用 Python 标准库在本机执行，近即时且未单独计时；无机器人、仪器或人工改写计划

预期与证伪

Qwen 预期基线控制可能使观察不足、接近过大、动作过快；任一门槛失败即必须调整而非改标准。间隙通过不能抵消其他三项失败。

身份

Plan ID 为 Round 1 固定计划；完整 Plan ID 与 Request ID 见 P7 脱敏回执及案例包。

计划在执行前由 Qwen 生成并保存，没有根据结果反向补写预期。

P15 | 第一轮实验执行与结果

步	动作/参数	原始结果	质量/差异	资源
1	固定基座； 250ms/1/1	run_id: sim-0be3f41b ac05afd1 task=succeeded	摘要一致	本地即时
2	动作/阶段生成	4 路点、7 阶段、 physical=false、writes=0	只证明接口形式	无机器人
3	保存指标	0.943；3.19mm；0.658； 40.27mm	前三项失败，间隙通过	单次请求
4	程序评价	false,false,false,true； adjust	完整保留失败	确定性

第一轮评价

内容	口径	结果	达到
任务分支	succeeded	succeeded	是
置信度（构造）	≥ .95	.943	否
接触误差（构造）	≤ 3.0mm	3.19mm	否
速度占比（构造）	≤ .60	.658	否
最小间隙（构造）	≥ 40mm	40.27mm	是
综合判定	全部 true	adjust	未通过

不确定性

数值由确定性公式生成，无测量噪声、真值标定或置信区间。0.943 和 3.19mm 是触发门槛的测试夹具，不能解释为相机测量或真实接触误差。

原始工件

三份 Round 1 JSON 分别保存计划、原始结果与程序评价；评价明确记录“模型未赋予任务结果”。

API 的 task_result=succeeded 不等于综合实验通过；第一轮真实结论是 adjust。

P16 | 第一轮问题分析与调整依据

问题	判断依据	可能原因/替代解释	Round 2 调整
置信度 0.943	低于 0.95	观察窗口不足的构造响应；非真实视觉退化	观察时长 250→500ms
误差 3.19mm	高于 3.0mm	观察/接近控制的构造响应；非接触真值	接近幅度 1.00→0.85
速度 0.658	高于 0.60	动作时标的构造响应；非真实动力学测量	时标 1.00→1.20
间隙通过	40.27 满足	不是全部指标共同恶化	不改阈值/任务/保护
证据等级有限	physical=false	改善可能仅来自公式单调性	仍只作软件验证

触发逻辑

1. 程序保存结果后生成 adjust 和 checks；
2. Round 2 上下文包含计划、请求、指标和 checks；
3. Qwen 必须保留问题、固定基座、seed、mode、scenario、guardian 和标准；
4. 三控制量仅允许 250–650ms、.80–1.00、1.00–1.30；
5. 程序逐项核对 failed check、observed/criterion 与 from/to。

保持不变

任务内容/顺序、固定基座、执行器、评价函数、阈值、seed、保护状态、scenario、输出结构和证据等级全部不变，以便把结果变化归因到动作控制量调整。

预期与代价

预期置信度上升、误差下降、速度降低且间隙继续通过；新增一次 Qwen 调用（2403 tokens）和证据管理成本，但不增加物理真实性。

Qwen 证据映射

“0.943<.95→ 观察 250 到 500ms；3.19>3.0→ 接近 1 到.85；.658>.60→ 时标 1 到 1.20。”完整映射见plan-diff.json。

替代解释保留：第二轮首先说明构造型执行器对动作控制量的预期响应。

P17 | 第二轮实验计划、执行与结果

变化	Round 1	Round 2	原因/结果
任务/顺序	黄色按钮；计划 → 执行 → 评价	相同	同题；task 均 succeeded
基座位姿	.18/- .08/12°	.18/- .08/12°	固定不变
观察时长	250ms	500ms	0.943 低于.95；R2 定位置信度.958 通过
接近幅度	1.00	.85	3.19mm 高于 3.0；R2 为 2.99mm，仅余.01mm
动作时标	1.00	1.20	.658 高于.60；R2 速度占比.466 通过
数据获取	同一执行器/JSON	相同	run_id=sim-a390754c41873cb3
分析	四项冻结门槛	相同	checks 全 true
停止	任一失败 →adjust	全通过 →accept	当前软件案例停止

两轮同口径结果

构造指标	Round 1	Round 2	变化
定位置信度	.943	.958	+.015
接触误差/mm	3.19	2.99	-.20
速度占比	.658	.466	-.192
最小间隙/mm	40.27	40.87	+.60
程序判定	adjust	accept	通过门禁

第二轮结论

改善	三项失败指标跨过门槛；间隙继续通过；动作计划四个路点真实改变
余量	接触误差 2.99mm 仅比 3.0mm 门槛低 0.01mm；不称稳健通过，需更多任务/噪声证据
未改善/代价	未增加物理真实性、样本多样性或统计证据；增加模型调用和 schema 维护
对最初判断	支持固定基座下有界动作反馈可改变软件准入判定
停止理由	accept 后继续调参是无意义优化；物理问题需新证据等级

调用身份

Round 2 Plan ID 为yellow_button_round_2；完整 Request ID 见 P7 脱敏回执；本轮消耗 2403 tokens。

改善是同一软件口径下由 adjust 变 accept，不升级为物理成功。

P18 | 实际对照、消融与方案优势

同条件反馈策略消融




图 3 | 对照只回答“反馈策略是否改变下一轮软件计划与判定”，不回答真实机器人性能。

对象	相同条件	结果	结论/代价
无反馈基线	共享第一轮证据/参数预算/seed/执行器/评价；原样重放 R1	adjust；250ms/1/1	不读取结果就无计划变化
规则式反馈	同上；固定规则 450ms/.90/1.10	adjust；误差 3.04mm	简单规则仍卡在门槛外
Qwen 反馈	同上；把原始结果 +checks 传 Qwen；schema 验证	accept；500ms/.85/1.20	改变软件判定；增加 2403 tokens

结构化门禁消融（定向测试）

输入变体	改变内容	实际结果
阈值改变	置信度门槛改 0.90	校验器拒绝，不执行
seed 改变	11 改 12	拒绝，防随机条件制造改善
改变固定基座	R2 改任一位姿值	拒绝，保证同一外部条件
科学问题改变	其他字段合法	拒绝，保证同题

实际改善与未改善

科学逻辑	第一轮失败项追溯到第二轮参数，不把重新生成当反馈
技术方法	模型、程序、人工权责分开；对象可机器比较
结果表现	本例 Qwen 反馈由 adjust 转 accept；无反馈和当前固定规则仍 adjust
未改善	未验证开放问题、真实噪声、仪器控制或 G1 动力学规划质量
新增成本	Qwen 调用、schema、工件存储、提示词和阈值版本管理

公平性

三策略相同的是第一轮证据、参数预算、seed、执行器与评价口径；第二轮控制量是各策略输出，因此不宣称“同一执行输入”性能提升。规则式基线用于避免把任何反馈都归功于 Qwen；结论仅限本例优于当前固定规则。

对照回答反馈机制是否改变下一轮软件计划与判定，不回答机器人性能提升多少。

P19 | 总体结果、失败分析与适用边界

本作品已经证明	本作品尚未证明
真实 Qwen 调用进入了两轮计划链；第一轮证据能够追溯到第二轮参数；同一程序口径可重放；失败、回执和哈希均可查	真实 G1 成功率；视觉或力觉测量准确性；复杂任务泛化；统计显著性；长期自主实验；任何物理安全授权

范围	轮次/样本	主要结果	重复/问题
Qwen 案例	2 轮、2 次有效调用	adjust→accept；完整 diff	单案例不可泛化
策略对照	无反馈/规则式/Qwen	adjust/adjust/accept	指标为构造夹具
确定性回放	R1 20 次、R2 20 次	各 20/20 相同；指标向量各 1	只证明确定性
定向测试	单元/HTTP E2E/只读校验	全通过；覆盖门禁、manifest、回放端点	未覆盖配额/网络抖动
API 分支	4 类场景	succeeded/abstained/aborted 可复现	非物理结果

失败与边界

问题	表现/原因	当前程度
模型格式可能越界	JSON 模式不保证业务 schema	最多 3 次明确纠正；不合规不执行
模型调整可能不足	首次正式周期为 adjust→adjust	不改阈值；明确安全余量目标，失败周期留存但不作主案例
静态 Pages 无 API	交互页需本地/Codespaces API	文档已明确启动/配置
指标无物理真值	公式夹具，无图像/传感器/物理引擎	只验证反馈链路
真实 G1 未闭环	案例无物理执行	需授权、标定、保护与不可变证据
报名页缺失	本机未找到盖章截图	自动替换槽；提交前必须补

用户、成本与责任

可服务评委、开发者和研究工程师核验模型规划是否真实进入反馈闭环；减少手工拼接证据，但增加 schema 和证据治理成本。研究者必须决定问题、阈值来源、仪器安全、物理授权与最终结论。

成功周期选择边界

首次周期qwen-cycle-0be3f41b-ff691f9e 为 adjust→adjust（R2 误差 3.05mm）；当时完整包被覆盖，只保留捕获摘要和 Request ID，见failed-cycle-disclosure.json。当前成功周期来自提示目标修订，不能推导 Qwen 成功率；脚本现会自动独立留存未来失败周期。

尚不能支持

真实机器人成功率、视觉/力觉测量、长时自主实验、并行仪器、真实噪声统计、领域专家结论、受限数据部署和公网托管 API。

最强结论是“可审计的 Qwen 两轮软件反馈闭环已运行”，不是“自主机器人科学家已完成”。

P20 | 代码复现与提交材料

交付	内容/入口
源码/环境/依赖	https://github.com/v6582374-netizen/Shaka ; Dev Container 为 Python 3.12, 提交 API 与验证器仅依赖 Python 标准库; 运行方法见下
Qwen 调用凭证	<code>artifacts/qwen-feedback-cycle/qwen-receipts.json</code> : 两次脱敏 Request ID、模型、端点、时间、token 与输入/输出 SHA-256; 未提交截图, API Key 不留存
代表案例	https://github.com/v6582374-netizen/Shaka/tree/main/artifacts/qwen-feedback-cycle
摘要/API	<code>GET/v1/qwen/evidence</code> ; <code>manifest</code> 验证后 <code>POST/v1/qwen/replay</code> ; OpenAPI 3.1
对照/总体材料	<code>method-comparison.json</code> 、 <code>parameter-space-audit.json</code> 、 <code>artifact-manifest.json</code>
API/前端	本地/Codespaces 启动后访问/; 静态文档 https://v6582374-netizen.github.io/Shaka/
技术报告	https://v6582374-netizen.github.io/Shaka/paper/Shaka-Technical-Report.pdf
演示视频	当前未提交, 不以视频替代复现材料

最短复现

```
git clone https://github.com/v6582374-netizen/Shaka.git
cd Shaka
python3 scripts/verify_qwen_feedback_cycle.py
python3 -m unittest tests.test_qwen_planner tests.test_qwen_cycle_verifier tests.test_submission_api -v
python3 -m submission_api.server --host 127.0.0.1 --port 8787
curl -sS http://127.0.0.1:8787/v1/qwen/evidence
curl -sS http://127.0.0.1:8787/v1/qwen/replay -H 'Content-Type: application/json' -d '{}'
```

提交前自检

- ☒ PDF 按 P1–P20 组织且不超过 20 页，内容与实现一致。
- ☒ 案例含第一轮计划、结果、调整依据、第二轮和反馈对照。
- ☒ 失败、未改善、成本和边界均显式呈现。
- ☒ 源码、Qwen 回执、案例、API 和前端说明可核验。
- ☒ 仿真、模型推断与物理验证严格区分；密钥未入库。
- ☐ 提交前补盖章报名表两页截图并核对系统报名名称。

材料身份

cycle: `qwen-cycle-0be3f41b-a390754c`; 有效调用 3490 tokens; `physical execution=false`; `credential recorded=false`; `claim boundary=deterministic_contract_simulation_only`。只读复现不联网；重新生成案例需百炼网络、凭证和费用。

除 P1 盖章报名材料外，P1–P20 技术内容、两轮案例、Qwen 证据、对照、边界与复现入口均已形成。